

LK-01 — Inisiasi Proyek

Nama Proyek: MLOps-GempaWas Mata Kuliah: MLOps Tipe Tugas: Individual Tanggal: 12 Mei 2026

1. Identifikasi Masalah & Domain

1.1. Latar Belakang

Indonesia berada di Pacific Ring of Fire dan mengalami rata-rata sekitar 6.000 gempa bumi per tahun. Setelah gempa besar ($M \geq 5.0$), biasanya terjadi serangkaian gempa susulan (*aftershocks*) yang dapat berlangsung sehari-hari hingga berminggu-minggu. Banyak korban jiwa dan kerusakan tambahan justru disebabkan oleh gempa susulan yang merobohkan bangunan yang sudah retak — pola ini terdokumentasi di kasus gempa Lombok 2018, Palu 2018, dan Cianjur 2022.

Saat ini, BPBD dan tim SAR mengandalkan intuisi senior atau aturan empiris (Omori's Law klasik) yang **belum disesuaikan untuk karakteristik geologi Indonesia per zona seismik**. Tidak ada API publik yang menyediakan probabilitas gempa susulan berbasis kombinasi sekuens seismik dan karakteristik zona.

1.2. Domain

Aspek	Detail
Domain utama	Mitigasi bencana geofisika (<i>disaster response & earth sciences</i>)
Sub-domain	Operasional darurat BPBD, perencanaan SAR, asuransi
Stakeholder	BPBD provinsi/kabupaten, BNPB, media massa, aplikasi kesiapsiagaan warga, perusahaan asuransi

1.3. Machine Learning Task

Item	Detail
Tipe task	Binary Classification (klasifikasi biner)
Pertanyaan utama	"Setelah gempa $M \geq 5.0$, apakah dalam 24 jam ke depan akan ada susulan $M \geq 4.0$ dalam radius 100 km?"
Output	Probabilitas kelas positif (0.0 – 1.0) yang di-update tiap jam selama 7 hari pasca mainshock
Model terpilih	XGBoost (single framework — sesuai instruksi "pilih satu saja")
Baseline pembanding	Omori's Law klasik ($n(t) = K/(t+c)^p$)

Mengapa XGBoost? Karena data bersifat tabular dengan ~10 fitur numerik + 1 categorical, class imbalance moderat (~25% positif), dan XGBoost terbukti dominan di Kaggle untuk skenario ini. Dibandingkan random forest, XGBoost punya `scale_pos_weight` built-in dan early stopping yang lebih elegant.

2. Analisis Karakteristik Data Bergerak

2.1. Sumber Data (Streaming, Public APIs)

Data berasal dari **dua sumber publik gratis tanpa API key**:

Sumber	Endpoint	Karakteristik
USGS Earthquake API	<code>https://earthquake.usgs.gov/fdsnws/event/1/query</code>	Global, GeoJSON, near-real-time (lag 5–15 menit), public domain
BMKG Open Data	<code>https://data.bmkg.go.id/DataMKG/TEWS/gempaterkini.json</code> + <code>gempadirasakan.json</code>	Indonesia-spesifik, JSON, sangat cepat untuk gempa lokal, plus intensitas MMI per kota

Pemakaian dua sumber memberikan **resiliensi** (jika satu down, satu lagi tetap aktif) dan **cross-verification** (gempa yang sama dilaporkan dua sumber dapat dibandingkan magnitudonya).

2.2. Modalitas & Tipe Data

Data adalah **tabular numerik + metadata teks**, time-stamped per event. Bukan gambar, bukan teks panjang, bukan audio. Volume per event sangat kecil (~1 KB JSON), namun frekuensinya **terus mengalir** (streaming, event-driven).

2.3. Cara Data Berubah / Bertambah

Dimensi	Bagaimana berubah
Volume	~16 event baru per hari rata-rata (~6.000/tahun)
Velocity	Bervariasi: 0 event/jam di kondisi tenang, sampai 50+ event/jam selama aftershock sequence besar
Distribusi magnitude	Shift saat ada sequence besar (banyak event kecil-menengah dalam waktu singkat)
Distribusi spasial	Shift saat aktivitas tektonik bergeser antar zona (Jawa vs Sumatra vs Sulawesi)
Coverage temporal	Dataset historis ~10 tahun (2015–2025) untuk training awal, terus bertambah ke depan

2.4. Tipe Drift yang Diantisipasi

Tipe drift	Contoh skenario di GempaWas
Covariate drift — $P(X)$ berubah	Sequence aftershock besar menggeser distribusi magnitude & rate event
Prior probability drift — $P(y)$ berubah	Periode tenang vs periode aktif → proporsi label positif berubah
Concept drift — $P(y X)$ berubah	Karakteristik fisika zona kerak berubah perlahan (jangka tahunan); juga peningkatan kualitas sensor BMKG bisa mengubah completeness magnitude

Karena $P(y | X)$ **secara fisika relatif stabil** (Omori's Law berlaku universal), drift utama yang harus ditangani adalah **covariate drift** akibat sequence events. Inilah yang akan dimonitor menggunakan Population Stability Index (PSI).

3. Strategi Continual Learning (CL) / Continuous Training (CT)

Sistem GempaWas mengadopsi pendekatan **Continuous Training** berbasis **hybrid trigger**: kombinasi *scheduled retraining* dan *drift-triggered retraining*.

3.1. Mekanisme Pengambilan Data Berkala


Aktivitas	Frekuensi	Implementasi
Hourly ingestion	Setiap jam (menit ke-5)	GitHub Actions cron <code>5 * * * *</code> menjalankan <code>src/ingestion.py</code>
Backfill historis	Sekali di awal, on-demand	Manual run dengan <code>--hours 720</code> untuk 30 hari
Weekly snapshot DVC	Setiap Senin pagi	<code>dvc add data/processed/features.parquet</code> lalu commit & tag <code>data-vX.Y</code>

3.2. Pemicu (Trigger) Retraining Otomatis

Sistem menggunakan **3 jenis trigger** yang bersifat komplementer:

Trigger	Kondisi	Aksi
Scheduled (mingguan)	Tiap Senin 03:00 UTC	Retrain tanpa kondisi, untuk safety net
Drift-based	PSI feature <code>magnitude</code> ≥ 0.1 ATAU PSI <code>depth</code> ≥ 0.1	Trigger workflow <code>weekly_retrain.yml</code> dengan <code>force_retrain=true</code>
Performance-based	F1-score 30-hari sliding window turun $\geq 10\%$ dari champion	Sama: trigger retrain + alert ke Slack/email (kalau di-setup)
Code-based (LK-08)	Push ke <code>main</code> yang mengubah <code>src/train.py</code> atau <code>src/features.py</code>	"Code as Trigger" — full automation chain

3.3. Alur CT End-to-End



3.4. Reproducibility & Lineage

Setiap model production memiliki **lineage trail** yang dapat di-trace:

- 1. **Code version:** Git commit SHA
- 2. **Data version:** DVC pointer hash (file `*.dvc`)
- 3. **Experiment params:** MLflow run ID
- 4. **Model artifact:** MLflow Model Registry version number
- 5. **Tag rilis:** Git tag `v0.X.Y` di `main`

Audit "model XYZ dilatih kapan dengan data apa" cukup query MLflow Registry → ikuti tag → cocokkan dengan DVC pointer → reproduce dengan `dvc checkout` + `git checkout` .

4. Penetapan Kriteria Keberhasilan

4.1. Metrik Teknis (ML)

Metrik	Target	Justifikasi
Primary: F1-score (kelas positif)	≥ 0.65 di test set	Class imbalance → F1 lebih informatif dari accuracy
Secondary: PR-AUC	≥ 0.72	Robust untuk imbalanced binary classification
Recall@Precision=0.7	≥ 0.60	BPBD lebih takut miss (false negative) daripada false alarm — tapi tetap precision dijaga supaya tidak cry-wolf
Beating baseline	XGBoost F1 > Omori-baseline F1 + 0.10	Wajib mengalahkan baseline fisika murni

4.2. Metrik Operasional (MLOps)

Metrik	Target	Tools
Pipeline uptime ingestion	$\geq 99\%$ (per bulan)	GitHub Actions success rate
Latency inference	< 200 ms p95	FastAPI + lazy model loading
Drift detection latency	< 1 jam setelah event	Quick check setelah tiap ingestion
Retraining cycle time	< 30 menit	GitHub Actions runner
Model rollback time	< 5 menit	MLflow Registry stage transition
Coverage tests	$\geq 80\%$ (<code>src/</code>)	pytest --cov

4.3. Metrik Bisnis / Produk

Metrik	Target	Mengapa penting
Coverage geografis	5 zona seismik utama (Jawa, Sumatra, Sulawesi, Maluku, Papua)	Indonesia luas, model harus generalize
Update frequency API	Update probabilitas tiap jam	Lebih cepat dari laporan manual BMKG
Adoption	Dipakai minimal 1 BPBD pilot dalam 6 bulan	Bukti relevansi nyata
Time-to-warning	< 1 jam dari kejadian mainshock	Window kritis untuk evakuasi bangunan retak
False alarm rate	$< 30\%$ di precision 0.7	Cry-wolf effect menurunkan kepercayaan stakeholder
Efisiensi operasional	Mengurangi waktu intuisi manual BPBD dari ~2 jam $\rightarrow$ < 5 menit per assessment	ROI utama dari segi tenaga kerja

4.4. Definition of Done untuk Production

Sebuah model dianggap **siap production** jika dan hanya jika:

1. $F1 \geq 0.65$ di test set time-based (bukan random split)
2. $PR-AUC \geq 0.72$
3. Mengalahkan Omori baseline minimal $+0.10$ F1
4. Latency p95 < 200 ms saat di-load dari MLflow Registry
5. Semua unit test pass (`pytest`)
6. Tidak ada data leakage (validated via feature audit)
7. Lineage lengkap: Git SHA + DVC pointer + MLflow run ID + tag rilis

5. Perancangan Diagram Arsitektur Pipeline

Diagram lengkap (7 layer: Source → Ingestion → Storage → Feature Engineering → Training → Serving → Users) ada di file terlampir:

- **PNG:** `/sessions/happy-wizardly-albattani/mnt/Project MLops/gempawas-mlops/docs/figures/lk03_arsitektur_etl.png` (gambar di halaman berikutnya)
- **SVG:** `docs/figures/lk03_arsitektur_etl.svg` (sumber editable)
- **Mermaid:** `docs/figures/lk03_arsitektur_etl.mmd` (sumber text)

Cuplikan struktur layer:

Layer	Komponen	Tool/Tech
1. Sources	USGS API, BMKG API	HTTP / public APIs
2. Ingestion	scheduled cron, ingestion.py, preprocess.py, quick drift	GitHub Actions, Python <code>requests</code>
3. Storage	raw JSON, SQLite operational, interim parquet, processed features	SQLite, Parquet, DVC versioning
4. Feature Engineering	identifikasi mainshock, rolling features, label compute	pandas, numpy
5. Training	weekly cron, train.py, MLflow tracking, Model Registry	XGBoost, MLflow
6. Serving	FastAPI inference, Streamlit dashboard, Docker container	FastAPI, Streamlit, Docker
7. Users	BPBD, BNPB, media, app warga, asuransi	REST API + UI

Continual Learning feedback loop (panah merah putus-putus di diagram) menghubungkan layer 2 (Quick Drift Check) langsung ke layer 5 (Training) — saat PSI melewati threshold, retraining ter-trigger tanpa intervensi manual.

6. Asumsi, Batasan, dan Risiko

6.1. Asumsi

1. Data BMKG & USGS akan terus tersedia gratis tanpa API key sepanjang proyek
2. Definisi "gempa besar" mengikuti standar BMKG ($M \geq 5.0$)

3. Definisi "susulan signifikan" adalah $M \geq 4.0$ dalam radius 100 km dan 24 jam setelah mainshock
4. GitHub Actions free tier mencukupi untuk hourly cron (2.000 menit/bulan untuk repo public, free)

6.2. Batasan

1. Tidak ada akses ke data sensor seismograf mentah (waveform), hanya katalog gempa
2. Tidak ada budget untuk hosting eksternal — semua di Codespaces + GitHub Actions
3. Dataset historis terbatas ~10 tahun data berkualitas dari BMKG
4. Single training framework (XGBoost) sesuai instruksi tugas

6.3. Risiko & Mitigasi

Risiko	Probabilitas	Dampak	Mitigasi
BMKG API down/berubah format	Sedang	Sedang	USGS sebagai fallback otomatis di <code>ingestion.py</code>
Class imbalance ekstrem	Tinggi	Sedang	<code>scale_pos_weight</code> XGBoost + fokus PR-AUC, bukan accuracy
Sekuens jarang di test set	Sedang	Tinggi	Time-based train/test split, bukan random
Model overfit ke zona Jawa (data terbanyak)	Sedang	Sedang	Stratified sampling per zona + separate evaluation per zona
Tidak ada gempa besar saat demo	Tinggi	Rendah	Replay demo pakai data historis Cianjur 2022
GitHub Actions quota habis	Rendah	Tinggi	Optimasi run time, cache pip, batas timeout 10 menit

7. Roadmap Eksekusi (Mapping ke LK)

LK	Fokus	Estimasi
LK-01 (selesai)	Inisiasi, problem framing, arch design	1–2 hari
LK-02	GitHub setup + Codespaces + cookiecutter	1–2 hari
LK-03	Desain ETL detail + diagram	2–3 hari
LK-04	Implementasi <code>ingest_data.py</code> + <code>preprocess.py</code>	3–5 hari
LK-05	DVC tracking + simulasi continual learning	2–3 hari
LK-06	<code>train.py</code> + MLflow tracking + 3+ runs	3–4 hari
LK-07	MLflow Model Registry + stage transition	2–3 hari
LK-08	GitHub Actions automation chain	3–4 hari
TOTAL		~3–4 minggu kerja

8. Kesimpulan Inisiasi

GempaWas adalah proyek MLOps yang **memenuhi semua syarat data dinamis**: ingestion otomatis dari API publik yang terus mengalirkan data baru tiap jam, dengan dua trigger continual training (scheduled + drift-based) untuk memastikan model tetap relevan terhadap perubahan karakteristik seismik Indonesia.


Pemilihan domain mitigasi gempa bukan sekadar untuk memenuhi tugas akademis — tapi punya **pain point nyata** (banyak korban Cianjur 2022 jatuh karena susulan), **label paling bersih** (gempa terjadi atau tidak, diverifikasi sensor), dan **baseline fisika defensible** (Omori's Law) sebagai pembanding ML.

Tools MLOps yang akan dipakai (cookiecutter, GitHub Codespaces, GitHub Actions, DVC, MLflow, Streamlit, Docker, XGBoost) sudah dipetakan secara eksplisit ke tiap LK berikutnya. Sistem ini dirancang dari awal untuk **production-grade**, bukan eksperimen one-shot.

Lampiran: Diagram arsitektur (`lk03_arsitektur_etl.png`)

GempaWas — Arsitektur Pipeline ETL & Continual Training

LK-03 • Data Ingestion → Feature Engineering → Training → Serving



GempaWas v0.1 • 2026